

Análise automática do Painel Coronavírus

Alberto Saa

UNICAMP

Resumo

A ideia deste pequeno projeto é a elaboração de um sistema em código Python para uma análise automática, no contexto de um modelo SIR simples, dos dados da epidemia de COVID-19 publicados diariamente pelo Ministério da Saúde. As análises diárias serão publicadas no endereço [1]. O objetivo do projeto é puramente educacional, com foco na análise de dados e programação em Python, e não em epidemiologia. Não obstante, todos os dados tratados aqui são reais e, portanto, os resultados talvez possam ter alguma relevância para se entender a dinâmica real da epidemia de COVID-19. Se for citar este sistema, por favor faça-o como:

- A. Saa, “*Análise automática do Painel Coronavírus*”, 2020. Texto integralmente disponível em <https://vigo.ime.unicamp.br/COVID/covid.pdf>

Todos os códigos e arquivos de dados pertinentes estão disponíveis no repositório [2]. Infelizmente, o autor não pode dar nenhum tipo de suporte para a utilização do sistema, mas incentiva a todos interessados a utilizar como quiserem as análises diárias assim como todo o material disponível no repositório.

1 Introdução

Diariamente, o Ministério da Saúde (MS) publica no site [3] alguns dados agregados sobre a epidemia de COVID-19 no País. Infelizmente, contrariando-se as práticas mais elementares para tratamento público de dados, a divulgação é feita diariamente em formato proprietário, especificamente numa

planilha Microsoft Excel. No entanto, isto pode ser facilmente corrigido, pois há várias ferramentas públicas, como o pacote LibreOffice, que permitem converter a planilha em Excel, por exemplo, em um arquivo de texto CSV (*comma-separated values*), o que permite sua ampla utilização. Utilizamos o formato CSV aqui.

De todos os dados publicados pelo MS, utilizaremos apenas o número de casos detectados, tanto em sua versão diária como total acumulado até uma certa data. Estes dados são interpretados no contexto do modelo epidemiológico mais simples: o modelo SIR.

2 Modelo SIR

Há uma vasta literatura sobre o modelo SIR e suas variantes, ver [4], por exemplo. Em sua versão mais simples, que é a empregada aqui, uma população de N indivíduos é dividida em três classe: os suscetíveis a infecção (S), os infectados (I) e os recuperados, ou removidos, (R). A ideia é simples. Os elementos suscetíveis S são aqueles que podem ser infectados a partir de contato com os infectados I . Já os elementos da classe R são aqueles que não mais se infectam nem infectam outros indivíduos, seja por cura com imunidade, seja por que foram afastados. Eventuais óbitos, neste tipo de modelo, são contados na classe R . A dinâmica do modelo é dada pelo sistema de EDO

$$\frac{dS}{dt} = -\frac{\beta IS}{N}, \quad (1)$$

$$\frac{dI}{dt} = \frac{\beta IS}{N} - \gamma I, \quad (2)$$

$$\frac{dR}{dt} = \gamma I, \quad (3)$$

sendo β e γ parâmetros positivos associados, normalmente, às taxas de infecção e de remoção, respectivamente, no modelo. Como admite-se $N = S + I + R$ constante, basta escolhermos duas classes para termos a descrição completa do modelo. Em nosso caso, escolheremos R e I .

Um dos parâmetros mais importantes neste tipo de modelo é o chamado número básico reprodutivo

$$r_0 = \frac{\beta}{\gamma}. \quad (4)$$

Trata-se de um adimensional cuja interpretação mais simples é o número médio de novos casos gerados por um infectado. A Eq. (2) pode ser escrita como

$$\frac{dI}{dt} = \left(r_0 \frac{S}{N} - 1 \right) \gamma I, \quad (5)$$

de onde podemos inferir alguns comportamentos qualitativos interessantes. Notem, primeiro, que $\frac{S}{N}$ é a fração dos suscetíveis na população, e portanto é um número no intervalo $[0, 1]$. É evidente de (5) que, para $r_0 < 1$, o número de infectados irá decrescer monotonicamente. Trata-se da extinção da epidemia. Para $r_0 > 1$, temos um comportamento qualitativo diferente. Para $r_0 \frac{S}{N} > 1$, o número de infectados cresce, implicando a expansão da epidemia. Porém, com a expansão da epidemia, a fração $\frac{S}{N}$ tende a diminuir, desacelerando o ritmo de crescimento do número de infectados. Ao chegar ao valor dado por

$$\frac{S}{N} = \frac{1}{r_0}, \quad (6)$$

o número de infectados I deixará de crescer, e a dinâmica do sistema (1)-(3) implicará na extinção da epidemia. Esta é a situação conhecida como “imunidade de rebanho” (*herd immunity*). Iremos considerá-la do ponto de vista dos indivíduos removidos R . Como $I = 0$ no estágio dominado pela imunidade de rebanho, temos que ele corresponde à situação com

$$n_R = \frac{R}{N} = 1 - \frac{1}{r_0} = \text{constante}. \quad (7)$$

A situação limite $r_0 = 1$ normalmente está associada a fases endêmicas da infecção. Nestas fases, o número de infectados permanece constante no tempo. Para nossos propósitos, basta notarmos que $r_0 > 1$ implica na expansão da epidemia e, quanto maior for o valor de r_0 , mais rápida será a expansão e maior será o coeficiente n_R dado por (7) para a imunidade de rebanho. Obviamente, quanto maior for r_0 , maior será o impacto da epidemia. Por outro lado, para $r_0 < 1$ a epidemia sempre se extingue, e quanto menor r_0 , mais rápida será esta extinção.

Necessitamos agora interpretar os dados divulgados pelo MS no contexto do modelo SIR. Tomaremos para nossa análise o número acumulado de casos confirmados. Dada a situação específica da epidemia de COVID-19, sabe-se que estes casos correspondem a indivíduos que, ou estão hospitalizados, ou acudiram a um hospital com sintomas moderados. É razoável supor que,

a partir deste diagnóstico, eles terminem internados ou liberados com recomendações estritas de isolamento e quarentena. Nessa situação, parece razoável considerá-los como elementos removidos R de nosso sistema, pois não se espera que continuem a propagar a doença, independente do resultado final, seja ela cura e imunização, ou óbito.

A determinação do número de infectados I é um problema muito mais complicado e delicado. Iremos estimá-lo usando a Eq. (3) e supondo γ constante. Os elementos de I são aqueles que estão infectados e transmitem a doença. No caso específico da epidemia de COVID-19, é razoável supor que estes são os infectados assintomáticos e também aqueles com sintomas leves que não são atendidos clinicamente e, portanto, desconhecem sua situação de infectado. Na ausência de testes em massa, estes números devem ser estimados a partir de outras observações. Esta é uma tarefa extremamente complexa e que está completamente fora do escopo deste pequeno projeto. Baseado nas análises apresentadas em [5], usaremos como hipótese que a relação entre os casos detectados e os reais está na faixa entre 1 : 10 e 1 : 20, correspondendo a fixar $\frac{1}{20} < \gamma < \frac{1}{10}$ na Eq. (3). Há consistentes indícios de relações entre casos detectados e reais desta mesma ordem de magnitude em outros Países [6]. Supondo-se γ constante, podemos obter a partir de (2) e (3).

$$r_0(t) = \frac{\ddot{R} + \gamma \dot{R}}{\dot{R} \left(\gamma - \frac{\gamma R + \dot{R}}{N} \right)} \quad (8)$$

Esta expressão para R_0 instantâneo será a base de nossa análise. É interessante notar que, enquanto estivermos longe da imunidade de rebanho, é natural admitir que $\frac{\gamma R + \dot{R}}{N} \ll 1$ e portanto teremos a aproximação

$$r_0(t) = 1 + \frac{\ddot{R}}{\gamma \dot{R}}. \quad (9)$$

Esta última expressão ajudará a entender porque a tendência de expansão ou extinção da epidemia não deve depender do valor de γ , pelo menos nos estágios longe da imunidade de rebanho.

3 Tratamento dos dados

Nossos dados são séries temporais diárias. Assim, iremos discretizar nossa variável independente $t \in \mathbb{Z}$. Todas as derivadas serão substituídas por dife-




Figura 1: Casos acumulados e novos casos para o estado de São Paulo, obtidos a partir dos dados publicados pelo Ministério da Saúde em [3]. É evidente a presença de “ruído” que impossibilita qualquer análise das variações diretamente destes dados.

renças finitas. Optou-se por diferenças atrasadas, *i.e.*

$$\dot{R}_t = R_t - R_{t-1} \quad \text{e} \quad \ddot{R}_t = \dot{R}_t - \dot{R}_{t-1}, \quad (10)$$

mas este ponto parece ter pouca influência no problema. A Fig. 1 mostra os casos acumulados (R_t) e os casos novos (\dot{R}_t) para o estado de São Paulo. É evidente destes dados que não conseguiremos realizar nenhuma análise que envolva diferenças finitas. Há inúmeras fontes de “ruído” nos dados. Não obstante, é claro que há um evidente regime de crescimento para as duas quantidades. Para podermos estimar r_0 a partir de (8), precisaremos “suavizar” os dados a fim de conseguir, pelo menos, a segunda derivada \ddot{R}_t de maneira minimamente suave.

Há diversas técnicas para suavização de dados. Utilizaremos a que talvez seja a mais simples de todas, a dos filtros de média móvel. A ideia subjacente destes filtros é substituir o valor de um elemento da série temporal por uma média calculada numa vizinhança simétrica com $2n + 1$ elementos, $n \in \mathbb{N}$,

$$\bar{R}_t = \frac{1}{2n + 1} \sum_{k=t-n}^{t+n} R_k. \quad (11)$$

A vizinhança sobre a qual se calcula a média é normalmente chamada de “janela” do filtro. Este tipo de filtro é extremamente atraente para o nosso problema específico, já que um dos ruídos mais comuns neste tipo de dado é a defasagem de alguns dias na incorporação de novos casos. Por certo, esta

é a fonte principal do ruído de período semanal presente na Fig. 1. Vários casos do fim de semana acabam notificados apenas na segunda ou terça-feira. Este tipo de problema pode ser conveniente sanado com filtros do tipo média móvel, com $n = 3$. Este será nosso filtro padrão.

Uma observação mais atenta de (11) revela que este filtro, como posto, só está definido para uma sequência com k elementos apenas para $n < t < k - n$. Nas regiões próximas às “bordas” da sequência, não conseguimos mais definir a vizinhança simétrica e não podemos calcular (11). Para resolver este problema, devemos impor algumas condições sobre as médias móveis próximas as bordas da sequência. Esta é uma questão delicada em qualquer análise de séries temporais, pois estas condições devem ser escolhidas a fim de não comprometer as tendências que queremos identificar. Na prática, devemos estender a sequência R_t acrescentando $2n$ novos elementos, correspondentes a $-n < t \leq 0$ e $k < t \leq k + n$. Para o problema em questão, optamos pelas seguintes extensões

$$R_{1-j} = R_1 \text{ e } R_{k+j} = R_k + R_{k-n+j} - R_{k-n}, \quad (12)$$

para $1 \leq j \leq n$. A primeira condição é evidente, admitimos a sequência constante na borda esquerda. A segunda condição parece menos clara, mas é também muito simples. Estamos admitindo que os n elementos R_t da sequência com $k - n \leq t < k$, devidamente deslocados verticalmente, sucedem o último elemento da esquerda da sequência original. Ambas extensões equivalem a supor que as tendências de crescimento são preservadas nas bordas da sequência. Assim, podemos definir o filtro (11) para uma sequência R_t para qualquer $1 \leq t \leq n$.

O filtro (11) pode ser visto também como a convolução da função R_t com uma função retangular de altura 1 e largura $2n+1$. É comum iterarmos a ação destes filtros. Por exemplo, duas aplicações sucessivas de um filtro do tipo média móvel com janela de $2n + 1$ elementos, corresponderá a convolução da sequência original com uma função triangular com largura $2n + 4$, por isso o nome de filtro triangular para dois usos sucessivos do filtro de média móvel. Uma terceira iteração corresponderia a um filtro de convolução com uma função quadrática e janela $6n + 3$, e assim sucessivamente. Escolhemos para o tratamento de nossos dados o filtro correspondente a 4 iterações de (11) com $n = 3$. Isto corresponde a uma convolução com uma função cúbica sobre uma janela de 4 semanas.

A Fig. 2 mostra os dados da Fig. 1 devidamente suavizados com nosso




Figura 2: Acima: Casos acumulados e novos casos para o estado de São Paulo, obtidos dos dados publicados pelo Ministério da Saúde em [3], e suavizados com 4 iterações de (11) com $n = 3$, correspondendo a um filtro cúbico com janela de um mês. Abaixo: Segunda derivada \ddot{R}_t , calculada a partir da série suavizada, e r_0 , calculado a partir de (8).

filtro, assim como o resultado do cálculo de \ddot{R}_t e de r_0 de acordo com (8). O gráfico para r_0 merece mais explicações. A linha horizontal corresponde a $r_0 = 1$. Acima dessa linha, temos expansão da epidemia. Para debelá-la antes de atingirmos a imunidade de rebanho, devemos sempre ter r_0 abaixo desse limiar. É clara a correlação que existe entre picos de r_0 e regiões de aceleração de casos, basta comparar o gráfico de r_0 com o de novos casos. O gráfico de r_0 apresenta uma região delimitada pelo valor de r_0 calculado a partir de (8) para os limites que consideramos para o parâmetro γ : $\frac{1}{20}$ e $\frac{1}{10}$, já que é razoável supor que o valor de r_0 esteja contido nessa região. Note que, pela natureza dos filtros utilizados, é prudente descartarmos as regiões das bordas. Por isso, o valor de r_0 efetivo sempre é calculado e mostrado com o alerta de estar 3 dias (o valor de n) atrasado.

4 Resultados

Os resultados publicados diariamente em [1] consistem na análise dos dados publicado sem [3] para os seguintes casos: Brasil, Estado de São Paulo, Cidade de São Paulo, Cidade de Campinas, e em seguida todos os outros estados do País e o Distrito Federal, ordenados por população. Para cada caso, são calculados e apresentados graficamente os casos novos e acumulados, com suas respectivas suavizações, os valores de r_0 determinados a partir de (8) com $\frac{1}{20} \leq \gamma \leq \frac{1}{10}$, e a previsão para os próximos 5 dias para o número de casos acumulados. Esta previsão é feita a partir de uma regressão linear simples dos últimos 10 dias da série R_t . Também são calculados o r_0 efetivo das últimas 2 semanas como a média simples dos valores calculados a partir de (8) nesse período, e os respectivos limiares de imunidade de rebanho associados, a partir de (7).

As tendências identificadas nestas análises são muito mais importantes que os valores numéricos em si, já que em última instância estes valores devem ser entendidos dentro do limitado escopo dos modelos SIR com as grandes incertezas no parâmetro γ . As tendências, por outro lado, podem ser interpretadas como “sinalizadores” para o comportamento da epidemia, e não dependem do parâmetro γ para estágios distantes da imunidade de rebanho, como já pode ser adiantado de (9). Como ilustração destas análises, as Figs. 3 e 4 apresentam os resultados para quatro países que estão em estágio mais avançado da epidemia: Espanha, Itália, Estados Unidos e Reino Unido. É evidente que a contenção da epidemia (decréscimo do número de novos casos) ocorre nos períodos com $R_0 < 1$, independentemente do valor preciso de γ . Na ausência de intervenções farmacológicas, a única estratégia para diminuir efetivamente o valor de R_0 é dificultar a propagação do vírus, objetivo cuja maneira mais eficiente de ser alcançado para o caso de vírus respiratórios é diminuindo-se o contato social entre os indivíduos.

Referências

- [1] <http://vigo.ime.unicamp.br/COVID>
- [2] <https://github.com/albertosaa/COVID>
- [3] <https://covid.saude.gov.br/>

- [4] https://en.wikipedia.org/wiki/Compartmental_models_in_epidemiology
- [5] <https://ciis.fmrp.usp.br/covid19/>
- [6] <https://elpais.com/sociedad/2020-04-07/mas-del-90-de-contagios-estan-ocultos.html>

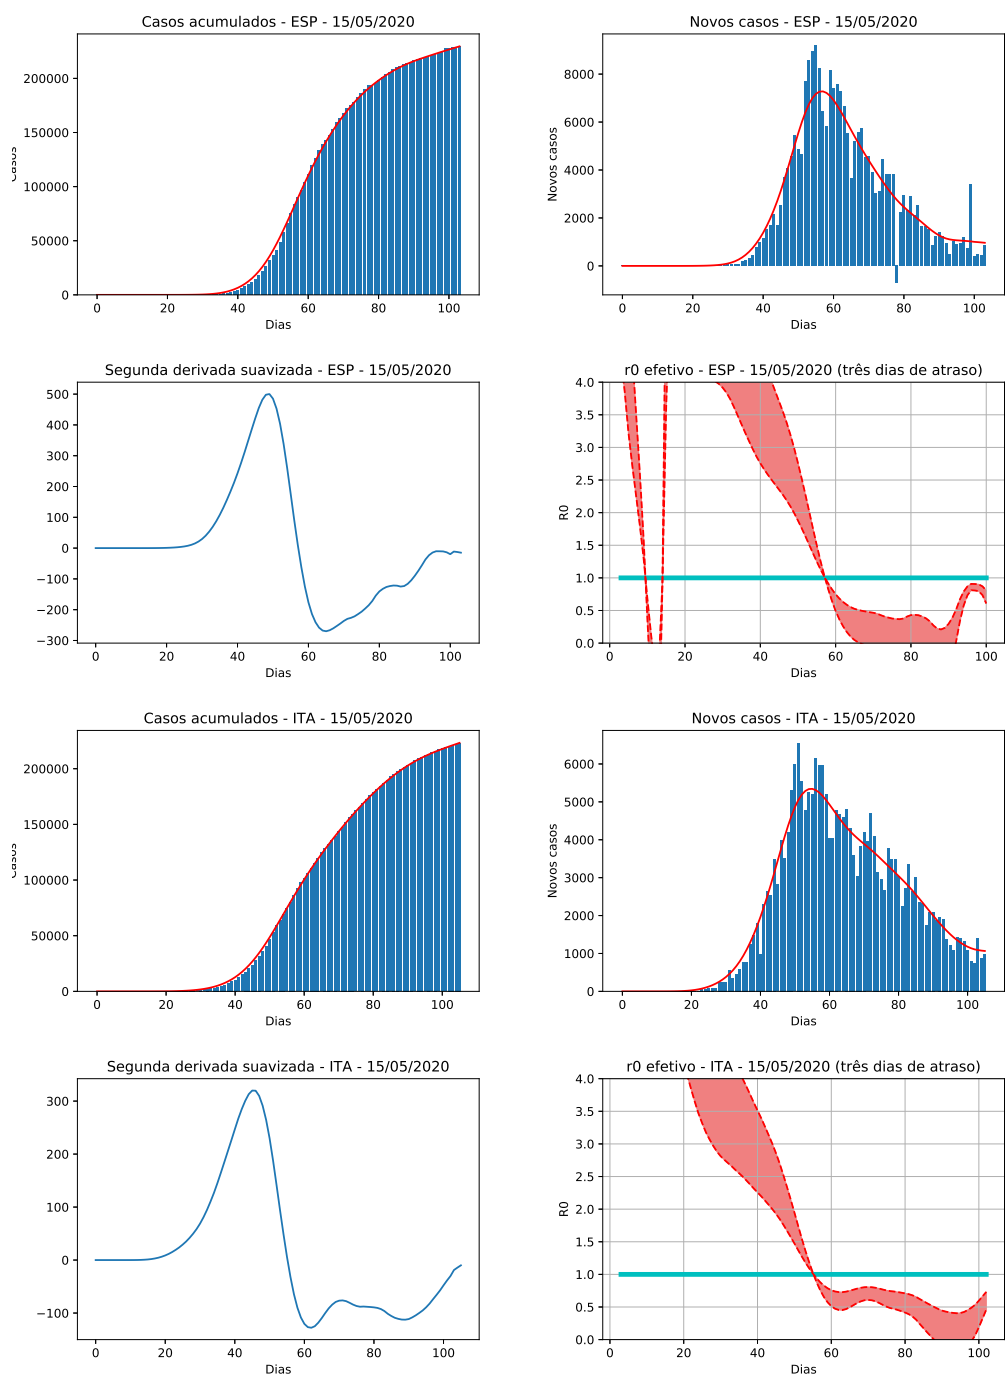


Figura 3: Análises para Espanha e Itália.

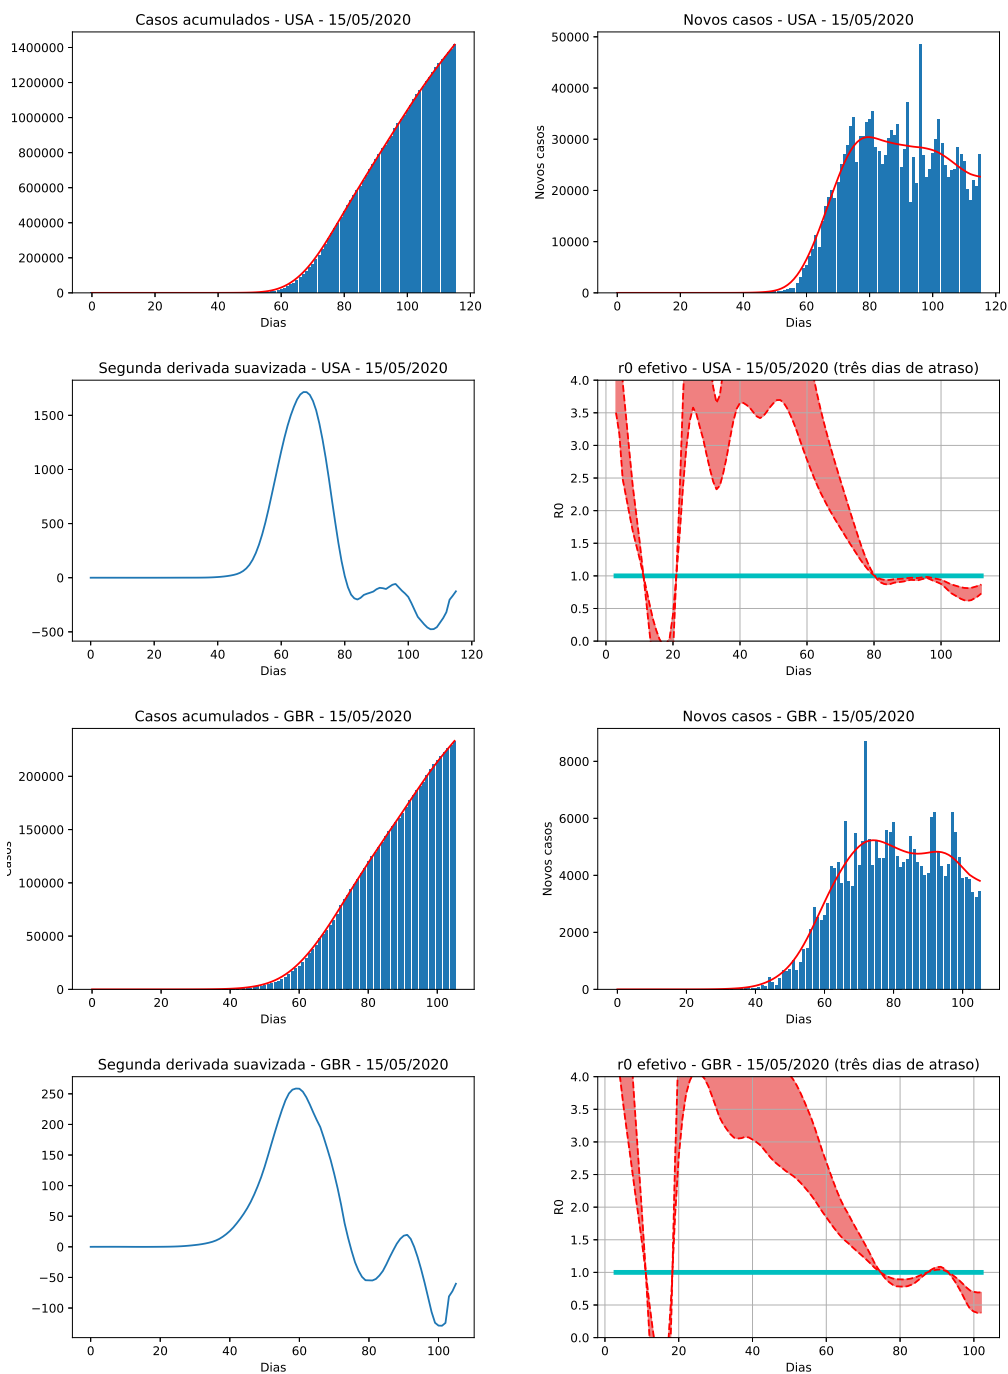


Figura 4: Análises para Estados Unidos e Reino Unido.